

## 第九章. 工具 = 期望

### 9.1 微积分储备知识

**泰勒级数:** 如果  $f$  是  $n$  次可微分的 (其中  $f^{(k)}(x)$  表示  $f$  在  $x$  处的  $k$  阶导数), 那么  $f$  在  $a$  点处的  $n$  阶泰勒级数就是

$$\begin{aligned} T_n(x) &:= f(a) + f'(a)(x-a) + \frac{f''(a)}{2!}(x-a)^2 + \cdots + \frac{f^{(n)}(a)}{n!}(x-a)^n \\ &= \sum_{k=0}^n \frac{f^{(k)}(a)}{k!}(x-a)^k. \end{aligned}$$

我们把  $f^{(k)}(a)/k!$  称为  $f$  关于  $a$  的第  $k$  个**泰勒系数**. 在很多应用中, 我们希望得到原点处的泰勒级数, 所以  $a = 0$  (在一些教材中, 这被称作**麦克劳林级数**). 泰勒级数给出了函数及其导数在一点处的性质, 由此可以估算出该函数在其他点处的值.

类似的是, 掌握大量相关信息后, 可以很好地得到近似

### 9.2 期望值和矩

**期望值, 矩:** 设  $X$  是定义在  $\mathbb{R}$  上的随机变量, 它的概率密度函数是  $f_X$ . 函数  $g(X)$  的期望值是

$$\mathbb{E}[g(X)] = \begin{cases} \int_{-\infty}^{\infty} g(x) \cdot f_X(x) dx & \text{若 } X \text{ 是连续的} \\ \sum_n g(x_n) \cdot f_X(x_n) & \text{若 } X \text{ 是离散的.} \end{cases}$$

最重要的情形是  $g(x) = x^r$ . 我们把  $\mathbb{E}[X^r]$  称为  $X$  的  $r$  阶矩, 把  $\mathbb{E}[(X - \mathbb{E}[X])^r]$  称为  $X$  的  $r$  阶中心矩.



两个重要的矩

- 期望 (一阶矩)
- 方差 (二阶中心矩)

## 9.3 均值和方差

**均值和方差:** 设  $X$  是一个连续型或离散型的随机变量, 它的概率密度函数是  $f_X$ .

- (1)  $X$  的**均值** (即**平均值或期望值**) 是一阶矩. 我们把它表示为  $\mathbb{E}[X]$  或  $\mu_X$  (当随机变量很明确时, 通常不给出下标  $X$ , 而只写  $\mu$ ). 具体地说,

$$\mu = \begin{cases} \int_{-\infty}^{\infty} x \cdot f_X(x) dx & \text{若 } X \text{ 是连续的} \\ \sum_n x_n \cdot f_X(x_n) & \text{若 } X \text{ 是离散的.} \end{cases}$$

- (2)  $X$  的**方差** (记作  $\sigma_X^2$  或  $\text{Var}(X)$ ) 是二阶中心距, 也可以说是  $g(X) = (X - \mu_X)^2$  的期望值. 同样, 当随机变量很明确时, 通常不给出下标  $X$ , 而只写  $\sigma^2$ . 把它完整地写出来, 就是

$$\sigma_X^2 = \begin{cases} \int_{-\infty}^{\infty} (x - \mu_X)^2 f_X(x) dx & \text{若 } X \text{ 是连续的} \\ \sum_n (x_n - \mu_X)^2 f_X(x_n) & \text{若 } X \text{ 是离散的.} \end{cases}$$

因为  $\mu_X = \mathbb{E}[X]$ , 所以在一系列代数运算后 (参见引理 9.5.3), 我们有

$$\sigma^2 = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - \mathbb{E}[X]^2.$$

这个式子把方差和  $X$  的前二阶矩联系起来, 在很多计算中都非常有用.

**标准差**是方差的平方根, 即  $\sigma_X = \sqrt{\sigma_X^2}$ .

- (3) **技术说明:** 为了保证均值存在, 我们希望  $\int_{-\infty}^{\infty} |x| f_X(x) dx$  (在连续的情形下) 或  $\sum_n |x_n| f_X(x_n)$  (在离散的情形下) 是有限的.

**方差与标准差:** 与方差相比, 标准差的优势在于它和均值有相同的单位. 因此, 标准差是衡量结果在均值附近波动幅度的自然尺度.



在均值相同的情况下，可以用方差来区分pdf.

关于技术说明：① 均值有限才有意义.

② 关于“ $1 \times 1$ ”

①:  $\int_{-\infty}^{+\infty} f(x) dx$  是反常积分. 当上下限趋 $\infty$ 的方式不一样时, 可能会出现无穷的情况. 因此仅知道其存在性是不够的.

② 反例:  $x f(x) = \frac{\sin x}{x}$ .

$\int_{-\infty}^{+\infty} f(x) dx$  是收敛的, 但其在正负间不断振荡, 不稳定. 而  $\int_{-\infty}^{+\infty} \left| \frac{\sin x}{x} \right| dx$  是发散的.



## 9.4 联合分布

**联合概率密度函数：**设  $X_1, X_2, \dots, X_n$  都是连续型随机变量，它们的概率密度函数分别是  $f_{X_1}, f_{X_2}, \dots, f_{X_n}$ 。假设每个  $X_i$  都定义在  $\mathbb{R}$  (实数集) 的一个子集上。那么， $(X_1, \dots, X_n)$  的联合概率密度函数就是一个非负的可积函数  $f_{X_1, \dots, X_n}$ ，满足：对于每一个恰当的集合  $S \subset \mathbb{R}$ ，均有

$$\text{Prob}((X_1, \dots, X_n) \in S) = \int \cdots \int_S f_{X_1, \dots, X_n}(x_1, \dots, x_n) dx_1 \cdots dx_n,$$

并且

$$f_{X_i}(x_i) = \int_{x_1 = -\infty}^{\infty} \cdots \int_{x_{i-1} = -\infty}^{\infty} \int_{x_{i+1} = -\infty}^{\infty} \cdots \int_{x_n = -\infty}^{\infty} f_{X_1, \dots, X_{i-1}, X_{i+1}, \dots, X_n}(x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n) \prod_{\substack{j=1 \\ j \neq i}}^n dx_j.$$

没有  $x_i$



我们把  $f_{X_i}$  称为  $X_i$  的边缘概率密度函数，可以通过对其他  $n-1$  个变量求积分来得到。

这  $n$  个随机变量  $X_1, \dots, X_n$  相互独立，当且仅当

$$f_{X_1, \dots, X_n}(x_1, \dots, x_n) = f_{X_1}(x_1) \cdots f_{X_n}(x_n).$$

对于离散型随机变量，只需要把积分替换成求和即可。

这是一个极其一般的情况，一般不考虑

联合概率密度函数是体现变量间相互依赖关系的方法之一

给定了  $n$  元组的概率



独立：

表 9-2  $(X, Y)$  的联合概率密度函数.  $X$  表示独立地抛掷 5 枚均匀硬币, 前 3 次掷出正面的次数;  $Y$  表示后 2 次掷出正面的次数

	$Prob(Y = 0)$	$Prob(Y = 1)$	$Prob(Y = 2)$	
$Prob(X = 0)$	$1/32$	$2/32$	$1/32$	$1/8$
$Prob(X = 1)$	$3/32$	$6/32$	$3/32$	$3/8$
$Prob(X = 2)$	$3/32$	$6/32$	$3/32$	$3/8$
$Prob(X = 3)$	$1/32$	$2/32$	$1/32$	$1/8$
	$1/4$	$2/4$	$1/4$	

任取  $X = k_1, Y = k_2$ .

$$Prob(X = k_1, Y = k_2) = Prob(X = k_1) \cdot Prob(Y = k_2)$$

不独立：

$$f_{U,V}(0, 2) = 0 \neq \frac{1}{8} \cdot \frac{2}{4} = f_U(0)f_V(2).$$

表 9-3  $(U, V)$  的联合概率密度函数, 其中  $U$  表示独立地抛掷 5 枚均匀硬币时前 3 次掷出正面的次数,  $V$  表示后 2 次掷出正面的次数

	$Prob(V = 0)$	$Prob(V = 1)$	$Prob(V = 2)$	
$Prob(U = 0)$	$1/16$	$1/16$	$0/16$	$1/8$
$Prob(U = 1)$	$2/16$	$3/16$	$2/16$	$3/8$
$Prob(U = 2)$	$1/16$	$3/16$	$2/16$	$3/8$
$Prob(U = 3)$	$0/16$	$1/16$	$1/16$	$1/8$
	$1/4$	$2/4$	$1/4$	

一个连续型联合概率密度函数 =

$$f_X(x, y) = \begin{cases} \frac{1}{\pi} & 0 \leq x^2 + y^2 \leq 1 \\ 0 & \text{其它} \end{cases}$$

$X$  的边缘概率密度函数 =

$$\begin{aligned} f_X(x) &= \int_{y=-\sqrt{1-x^2}}^{\sqrt{1-x^2}} \frac{1}{\pi} dy \\ &= \frac{2}{\pi} \sqrt{1-x^2} \end{aligned}$$

## 9.5 期望的线性性质

**定理 9.5.1 (期望的线性性质)** 设  $X_1, \dots, X_n$  是随机变量, 并设  $g_1, \dots, g_n$  是满足下列条件的函数:  $\mathbb{E}[|g_i(X_i)|]$  存在且有限. 令  $a_1, \dots, a_n$  表示任意实数. 那么

$$\mathbb{E}[a_1 g_1(X_1) + \dots + a_n g_n(X_n)] = a_1 \mathbb{E}[g_1(X_1)] + \dots + a_n \mathbb{E}[g_n(X_n)].$$

注意, 随机变量 不一定是相互独立的. 另外, 如果  $g_i(X_i) = c$  (这里的  $c$  是固定常数), 那么  $\mathbb{E}[g_i(X_i)] = c$ .

“和的期望等于期望的和”.



懒得抄证明了.

**引理 9.5.2** 设  $X$  是一个随机变量, 它的均值为  $\mu_X$ , 方差为  $\sigma_X^2$ . 如果  $a$  和  $b$  是任意两个固定常数, 那么随机变量  $Y = aX + b$  有下列结果

$$\mu_Y = a\mu_X + b \quad \text{和} \quad \sigma_Y^2 = a^2\sigma_X^2.$$

$$\begin{aligned}\sigma_Y^2 &= \mathbb{E}[(Y - \mu_Y)^2] \\ &= \mathbb{E} \left[ ((aX + b) - (a\mu_X + b))^2 \right] \\ &= \mathbb{E} [(aX - a\mu_X)^2] \\ &= \mathbb{E} [a^2(X - \mu_X)^2] = a^2 \mathbb{E} [(X - \mu_X)^2] = a^2 \sigma_X^2.\end{aligned}$$

**引理 9.5.3** 设  $X$  是一个随机变量, 那么

$$\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2.$$

$$\begin{aligned}\text{Var}(X) &= \mathbb{E}[(X - \mu_X)^2] \\ &= \mathbb{E}[X^2 - 2\mu_X X + \mu_X^2] \\ &= \mathbb{E}[X^2] - \mathbb{E}[2\mu_X X] + \mathbb{E}[\mu_X^2] \\ &= \mathbb{E}[X^2] - 2\mu_X \mathbb{E}[X] + \mu_X^2 \\ &= \mathbb{E}[X^2] - 2\mu_X \cdot \mu_X + \mu_X^2 \\ &= \mathbb{E}[X^2] - \mu_X^2 = \mathbb{E}[X^2] - \mathbb{E}[X]^2,\end{aligned}$$

## 9.6 均值和方差的性质

定理 9.6.1 如果  $X$  和  $Y$  是相互独立的随机变量, 那么

$$\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y].$$

一种特别重要的情况是

$$\mathbb{E}[(X - \mu_X)(Y - \mu_Y)] = \mathbb{E}[X - \mu_X]\mathbb{E}[Y - \mu_Y] = 0.$$

定理 9.6.2 (随机变量之和的均值与方差) 设  $X_1, \dots, X_n$  是  $n$  个随机变量, 它们的均值是  $\mu_{X_1}, \dots, \mu_{X_n}$ , 方差是  $\sigma_{X_1}^2, \dots, \sigma_{X_n}^2$ . 如果  $X = X_1 + \dots + X_n$ , 那么

$$\mu_X = \mu_{X_1} + \dots + \mu_{X_n}.$$

如果随机变量是相互独立的, 那么还能得到

$$\sigma_X^2 = \sigma_{X_1}^2 + \dots + \sigma_{X_n}^2 \quad \text{或} \quad \text{Var}(X) = \text{Var}(X_1) + \dots + \text{Var}(X_n).$$

如果这些随机变量是独立同分布的 (因此, 每个随机变量的均值都是  $\mu$ , 方差都是  $\sigma^2$ ), 那么

$$\mu_X = n\mu \quad \text{且} \quad \sigma_X^2 = n\sigma^2.$$

对于方差而言, 需要保证事件之间的独立性

反例:  $X$  与  $-X$ .

$$\text{Var}(X - X) = 0$$

$$\text{But: } \text{Var}(X) + \text{Var}(-X) = 2 \text{Var}(X).$$



对于随机变量之和的方差计算的证明 -  
重写代数表达式。

$$\begin{aligned}\sigma_X^2 &= \mathbb{E}[(X - \mu_X)^2] \\ &= \mathbb{E}[((X_1 + X_2) - (\mu_{X_1} + \mu_{X_2}))^2] \\ &= \mathbb{E}[(X_1 - \mu_{X_1}) + (X_2 - \mu_{X_2})]^2 \\ &= \mathbb{E}[(X_1 - \mu_{X_1})^2 + 2(X_1 - \mu_{X_1})(X_2 - \mu_{X_2}) + (X_2 - \mu_{X_2})^2].\end{aligned}$$

利用期望的线性性质, 可以把和的期望改写成期望的和, 即

$$\begin{aligned}\sigma_X^2 &= \mathbb{E}[(X_1 - \mu_{X_1})^2] + \mathbb{E}[2(X_1 - \mu_{X_1})(X_2 - \mu_{X_2})] + \mathbb{E}[(X_2 - \mu_{X_2})^2] \\ &= \sigma_{X_1}^2 + 2\mathbb{E}[(X_1 - \mu_{X_1})(X_2 - \mu_{X_2})] + \sigma_{X_2}^2.\end{aligned}$$


因为  $X_1$  与  $X_2$  独立,  $(X_1 - \mu_{X_1})$  与  $(X_2 - \mu_{X_2})$  也独立。

$$\begin{aligned}\text{所以, 有 } \sigma_X^2 &= \sigma_{X_1}^2 + 2\mathbb{E}(X_1 - \mu_{X_1}) \cdot \mathbb{E}(X_2 - \mu_{X_2}) \\ &\quad + \sigma_{X_2}^2 \\ &= \sigma_{X_1}^2 + \sigma_{X_2}^2\end{aligned}$$

$\Rightarrow$  利用期望的线性性质



## 9.7 偏斜度与峰度



三阶中心距



四阶中心距

偏斜度衡量了概率分布的对称性。

如：正态分布的偏斜度是0，完全对称。

偏斜度  $> 0$ ，则右侧尾巴比左侧更厚、长。

偏斜度  $< 0$ ，则左侧尾巴更厚、长。

峰度衡量的是概率密度函数到达峰值的方式。

峰度越小，到达峰值越平稳，反之有一个尖点和陡峭的落点。



## 9.8 协方差

**协方差:** 设  $X$  和  $Y$  是两个随机变量.  $X$  和  $Y$  的协方差记作  $\sigma_{XY}$  或者  $\text{Cov}(X, Y)$ , 它的表达式为

$$\sigma_{XY} = \mathbb{E}[(X - \mu_X)(Y - \mu_Y)].$$

注意,  $\text{Cov}(X, X)$  等于  $X$  的方差. 另外, 如果  $X_1, \dots, X_n$  都是随机变量, 并且  $X = X_1 + \dots + X_n$ , 那么

$$\text{Var}(X) = \sum_{i=1}^n \text{Var}(X_i) + 2 \sum_{1 \leq i < j \leq n} \text{Cov}(X_i, X_j).$$

①  $X_1, X_2$  的协方差为 0 并不代表两变量相互独立.

② 协方差衡量了两个变量的线性相关程度.

相关系数 =

$$\rho = \frac{\text{Cov}(X, Y)}{\sigma_X \cdot \sigma_Y}$$

是对协方差的标准化.  $\rho \in [-1, 1]$

绝对值越大越相关.



对于任意两变量  $X, Y$  有

$$\text{Cov}(X, Y) = E(X, Y) - \mu_X \mu_Y$$

证明:  $\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$

$$= E(XY - X \cdot \mu_X - Y \cdot \mu_Y + \mu_X \mu_Y)$$

$$= E(XY) - \mu_X \mu_Y$$